Domain Knowledge Hub: сховище знань для аналізу достовірності інформації

Whitepaper фінального проєкту курсу «Сховища знань та управління знаннями» · Хоптій Дмитро, ФЕІ-42, ЛНУ імені Івана Франка · листопад 2026 · версія сховища kb-2026.11-v1

Коротко. Hub зводить в одне сховище онтологію, граф розслідувань, корпус довідкових і внутрішніх документів, OLAP-куб перевірок і журнали роботи аналітиків. Поверх нього працюють RAG-чат з цитуванням, LLM-агент з інструментами лише для читання і рекомендаційний модуль, що пояснює кожну підказку шляхом у графі знань. Усе запускається однією командою Docker Compose і працює на звичайному ПК з локальною моделлю 7B, без передавання даних зовнішнім сервісам. Гібридні рекомендації дають nDCG@10 = 0,166 проти 0,054 у популярності. Агент відбиває 13 з 13 атак. Головне обмеження — оцінка рекомендацій на синтетичних журналах.

1. Проблема і користувачі

Фактчекер працює з потоком тверджень: перевіряє першоджерело, шукає спростування, застосовує регламент вердиктів і пояснює рішення. Знання для цього розпорошені:

- енциклопедичні статті про пропаганду й методи перевірки;
- внутрішні регламенти, що змінюються (регламент 2025 замінено регламентом 2026);
- досьє наративів з обмеженим доступом;
- історія попередніх вердиктів;
- мережі акаунтів-поширювачів.

Типові збої такі: застосування застарілого правила, пропущене спростування, вигадана моделлю цифра, витік закритого досьє.

Користувачі:

- **аналітик-фактчекер** (основний; роль analyst) — пошук доказів, відповіді з цитатами, рекомендації «що прочитати далі»;
- **керівник групи / адміністратор знань** (admin) — досьє наративів, контроль якості, схвалення нових фактів;
- **гість / стажер** (guest) — лише публічні матеріали, навчання.

Компетентнісні питання (ЛР7, ЛР9):

- «хто першоджерело твердження?»;
- «які офіційні джерела його спростовують?»;
- «чи відповідає вердикт чинному регламенту?»;
- «яка частка хибних вердиктів на платформі?»;
- «що ще варто прочитати аналітику, який вивчає дипфейки?».

2. Архітектура

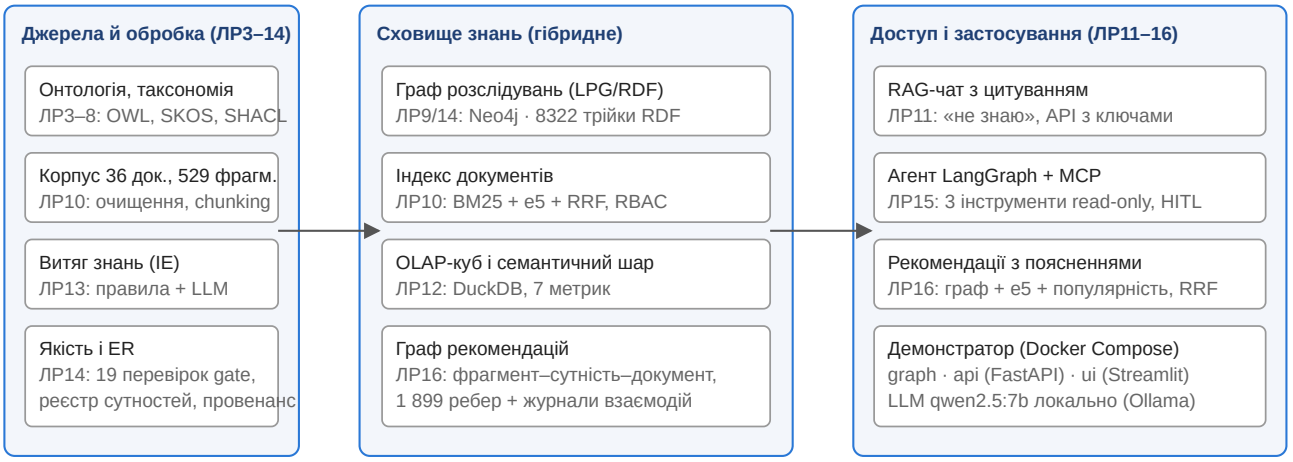


Рисунок 1 – Архітектура Hub: три шари й лабораторні, у яких їх побудовано

Гібридне сховище. Кожен тип питань обслуговує своя модель даних:

- **граф** (Neo4j LPG у ЛР9; RDF-знімок 8322 трійки для SPARQL у ЛР8/14) — зв'язки «акаунт → публікація → твердження → наратив → вердикт»;
- **індекс документів** (ЛР10) — 36 документів, 529 фрагментів, гібридний пошук BM25 + e5 + RRF з фільтром доступу до ранжування;
- **OLAP-куб** (ЛР12, зірка з 7 вимірами в DuckDB) — агреговані показники через семантичний шар із 7 метрик.

Шар застосувань:

- RAG-чат (ЛР11);
- агент LangGraph із трьома інструментами й MCP-сервером (ЛР15);
- рекомендаційний модуль (ЛР16).

Демонстратор — три контейнери з одного образу python:3.12-slim:

- `graph` — SPARQL лише для читання на pyoxigraph;
- `api` — FastAPI: рекомендації, пояснення, пошук, агент, проксі SPARQL;
- `ui` — Streamlit.

LLM qwen2.5:7b працює на хості через Ollama. Порти відкриті лише на 127.0.0.1, контейнери працюють від непривілейованого користувача, секретів немає. Запуск з нуля на ПК студента (Docker 27.5.1): збірка образу 5,1 хв, підйом трьох сервісів до стану healthy — 14 с; образ 944MB. Автоматичний прогін сценарію демонстрації пройшов 8/8 кроків (рекомендації з поясненнями, відповідь з доказом, «не знаю», три атаки, холодний старт).

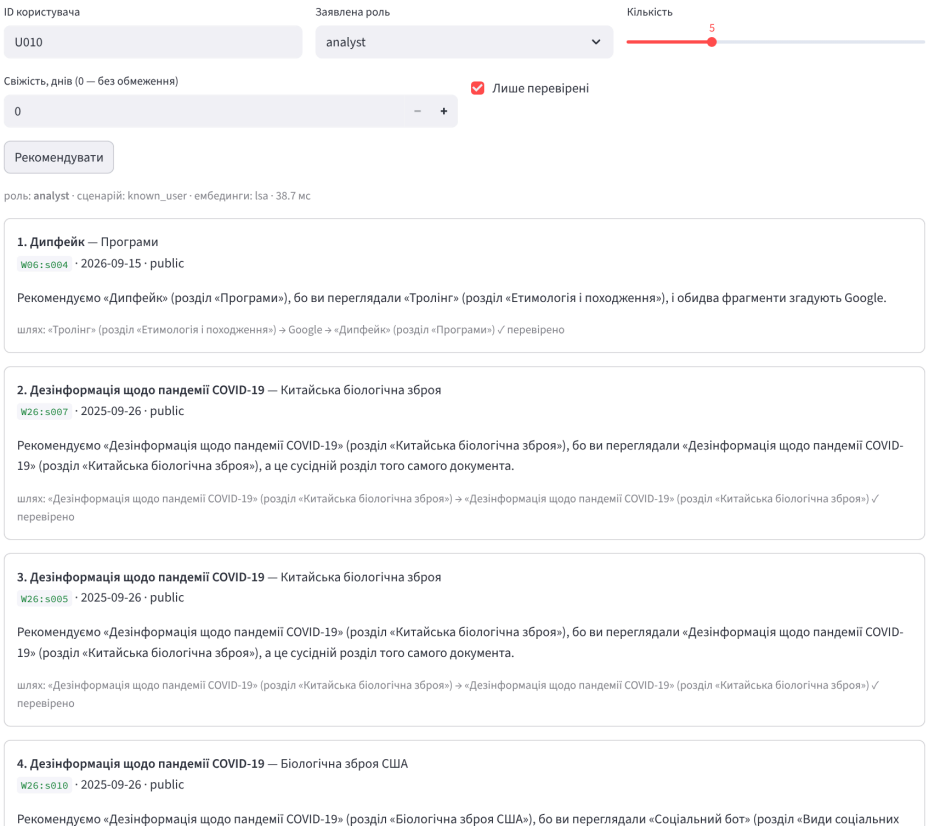


Рисунок 2 – Інтерфейс демонстратора: рекомендації аналітику з поясненнями зі шляхів графа

3. Знання і походження (provenance)

Онтологія. Вона пройшла шлях від таксономії й семантичної мережі (ЛР4–5) до OWL у Protégé (ЛР6) і має 18 класів, 13 object і 16 data properties. Узгодженість перевірено HermiT. RDF-сховище ЛР8 додало SHACL-форми й RDFS-виведення: той самий запит повертає 5 результатів замість 0.

Походження фактів. Кожне ребро графа несе `source`, `confidence`, `validFrom`; після ЛР14 жодного ребра без провенансу. Злиття сутностей (ER) зберігає вихідні записи і має операцію unmerge — хибне злиття YouTube ~ YouTuber скасовано. Суперечності розв'язуються за явними стратегіями («дата», «рішення власника», «канонічний термін»). 34 альтернативні значення збережено з походженням, а не стерто.

Нові факти агент *лише пропонує* (`propose_fact`, ЛР15). Пропозиція проходить SHACL-валідацію, оцінку ризику і схвалення людиною з записом PROV-O та журналом аудиту.

Витяг знань. На test правила spaCy дали F1 відношень 0,811 проти 0,163 у локальної LLM (ЛР13). Тому основний метод — правила, а LLM лише генерує кандидатів, яких фільтрує валідатор цитат.

4. Метрики якості (ЛР3–ЛР16)

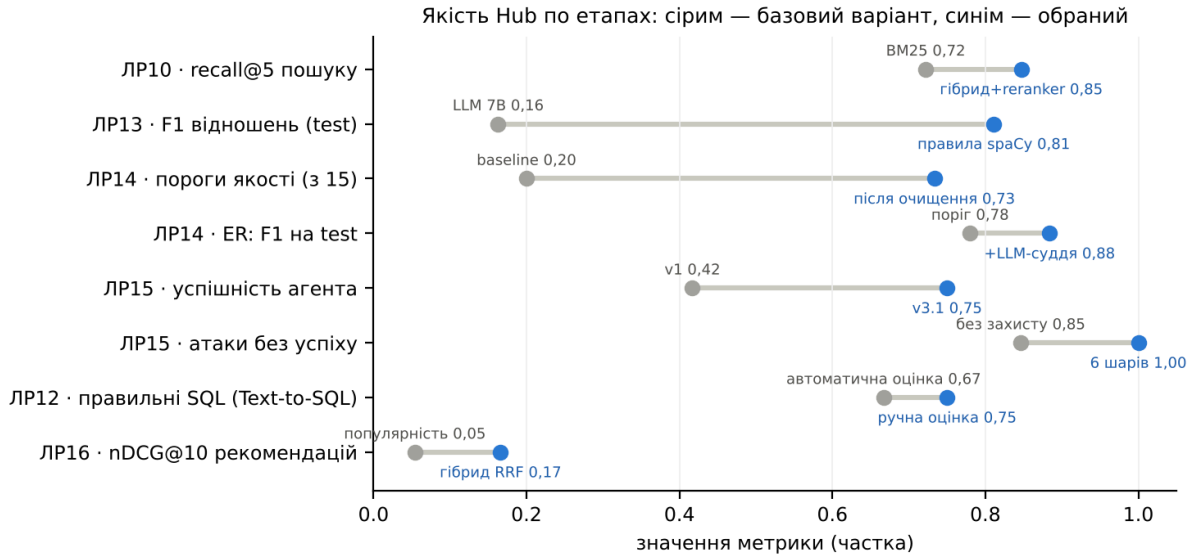


Рисунок 3 – Ключові метрики етапів: базовий і обраний варіант (дані звітів ЛР10–ЛР16)

ЛР	Що вимірювали	Результат
3–7	модель предметної області	глосарій, таксономія SKOS, семантична мережа; онтологія 18 класів, узгоджена (HermiT, 0 суперечливих класів)
8	RDF-сховище	SHACL: 3 форми; RDFS-виведення додало 499 трійок, запит класу 0 → 5 результатів
9	граф Neo4j	297 вузлів, 808 ребер; PageRank знайшов 8/8 першоджерел; Louvain модулярність 0,57; індекс −45 % db hits; Text-to-Cypher 50–58 %
10	пошук	recall@5: BM25 0,722 → гібрид+reranker 0,847; 0 порушень прав доступу
11	RAG	13/15 правильних, усі запити без відповіді відхилено; citation validity 1,0, context recall 0,875, citation accuracy 0,662; суддя завищує faithfulness (κ = 0,488)
12	OLAP і Text-to-SQL	2138 фактів без сиріт, 8 перевірок; Text-to-SQL 66,7 % (75 % вручну), атаки 3/3 заблоковано
13	витяг знань	F1 відношень: правила 0,811, LLM 0,163; прийнято 54/254 пропозицій LLM; κ розмітки 0,375
14	якість даних	пороги: 3/15 → 11/15; ER test P/R 0,889/0,696 → з LLM-суддею 0,950/0,826; gate із 19 перевірок блокує 3/3 дефекти
15	агент	успішність 0,417 → 0,75 (12 сценаріїв); атаки без захисту 2/13 успішні, із захистом 0/13
16	рекомендації	nDCG@10: популярність 0,054 → гібрид RRF 0,166; coverage@10 0,042 → 0,392; пояснень, що пройшли перевірку: шаблон 1,00, перефразування LLM 0,97 (строга перевірка 0,67); вставлені сторонні сутності виявлено 60/60

Таблиця 1 – Метрики якості за етапами

Рекомендації: офлайн-оцінка

Дані. Синтетичні журнали 60 користувачів за три місяці. Часове розбиття: train < 2026-10-06 ≤ validation < 2026-10-20 ≤ test. Ваги гібриду підбиралися лише на validation. Популярність і профілі рахуються від моменту межі, тож витоку з майбутнього немає.

Повтори. 5 seed генератора, у кожному бутстреп за користувачами (1000 вибірок). Ембединги: e5.

Конфігурація	P@5	R@5	nDCG@10	coverage@10	novelty@10
популярність	0,038 ± 0,005	0,043 ± 0,014	0,054 ± 0,009	0,042 ± 0,005	6,73
графовий	0,092 ± 0,024	0,137 ± 0,051	0,160 ± 0,047	0,464 ± 0,026	9,18
ембединги (e5)	0,072 ± 0,030	0,103 ± 0,038	0,122 ± 0,048	0,353 ± 0,014	9,68
гібрид зважений	0,107 ± 0,037	0,165 ± 0,068	0,179 ± 0,055	0,357 ± 0,122	8,48
гібрид RRF	0,096 ± 0,025	0,140 ± 0,036	0,166 ± 0,040	0,392 ± 0,022	8,59

Таблиця 2 – Офлайн-оцінка рекомендацій на test (середнє ± sd за 5 seed)

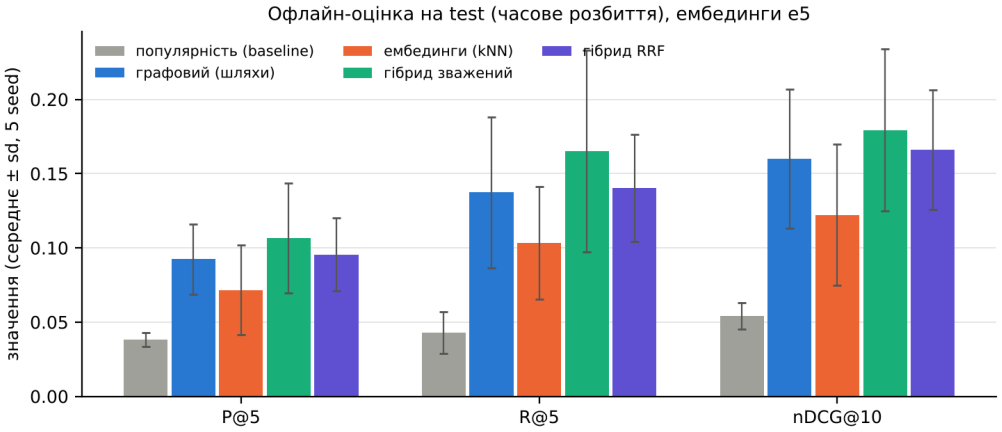


Рисунок 4 – P@5, R@5, nDCG@10 за конфігураціями

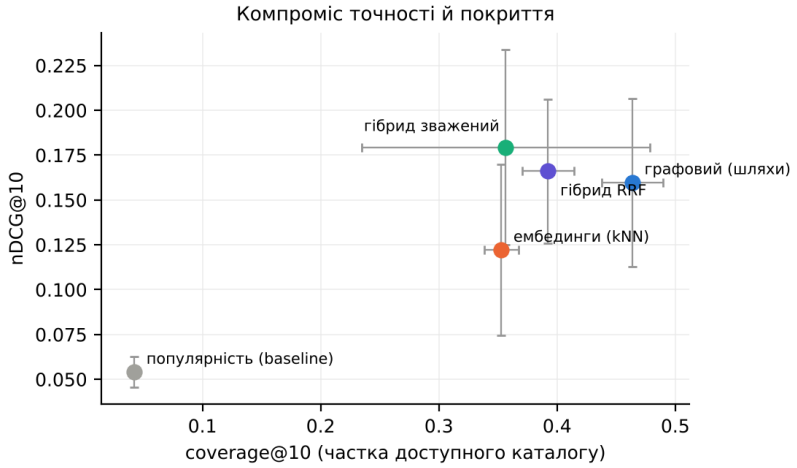


Рисунок 5 – Компроміс точності (nDCG@10) і покриття каталогу

Висновок. Обидва гібриди втричі кращі за популярність і кращі за кожен окремий метод. Зважений гібрид має трохи вищий середній nDCG@10 (0,179 проти 0,166). Але парний тест на тих самих 256 користувачах дає різницю 0,013, 95 % CI [-0,004; 0,030], тобто різниця незначуща. Для продукту обрано **RRF**:

- точність у межах похибки така сама, а розкид між seed менший (sd 0,040 проти 0,055);
- він не потребує навчуваних ваг — у зваженого гібриду оптимальні ваги стрибають між seed ((0,1; 0,6; 0,3), (0,4; 0,5; 0,1), (0,7; 0,3; 0,0), (0,1; 0,5; 0,4), (0,4; 0,4; 0,2)), тобто їх підбір переналаштовується на validation;
- покриття каталогу стабільніше (sd 0,022 проти 0,122).

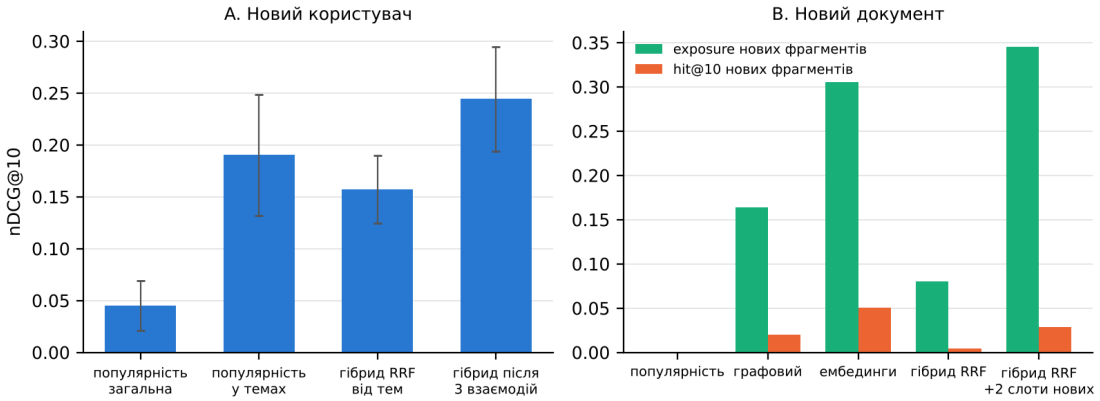


Рисунок 6 – Холодний старт: новий користувач (nDCG@10) і новий документ (exposure, hit@10)

Холодний старт:

- **новий користувач** обирає теми: гібрид від тем дає nDCG@10 = 0,157 проти 0,045 у загальної популярності; після трьох взаємодій — 0,244;
- **новий документ**: без примусових слотів RRF майже не показує нові фрагменти (exposure 0,080); з двома слотами — 0,345.

5. Ризики за AI Act і NIST AI RMF

Класифікація за AI Act. Регламент (ЄС) 2024/1689 зі змінами Digital Omnibus — Регламент (ЄС) 2026/1744. Hub — допоміжний інструмент аналітика для пошуку, рекомендацій і чернеток відповідей. Він не належить до заборонених практик (ст. 5) і не входить до переліку високоризикових систем Додатка III: не ухвалює рішень щодо осіб, не впливає на вибори, не використовується правоохоронними органами.

Обов'язки, що діють:

- **прозорість (ст. 50, з 2 серпня 2026)** — користувач знає, що працює з ШІ, а згенерований текст позначено: відповіді агента в UI мають позначку моделі; пояснення рекомендацій у демонстраторі — детерміновані шаблони зі шляху графа;
- **AI-грамотність персоналу (ст. 4)**.

Якщо систему почне застосовувати державний орган для рішень щодо громадян, класифікацію треба переглянути. Обов'язки для Додатка III після Omnibus діють з 2 грудня 2027 року. Обов'язки постачальника GPAI-моделі (ст. 53) лежать на розробнику qwen, а не на Hub.

NIST AI RMF 1.0. Функції Govern / Map / Measure / Manage і профіль генеративного ШІ NIST AI 600-1 зведено в реєстр ризиків:

Ризик	AI Act / NIST AI RMF	Як зменшуємо в Hub	Залишковий
Вигадані факти у відповіді агента	NIST: Valid & Reliable, Measure 2.5; GenAI-профіль: confabulation	цитування [id], верифікатор чисел у доказах, «не знаю»; успішність 0,75, але 3/12 сценаріїв хибні	середній
Ін'єкція промпту, підвищення ролі	NIST: Secure & Resilient; GenAI-профіль: information security	фільтр входу, роль із сесії, RBAC до ранжування, read-only граф, закріплені маніфести; атаки 13/13 відбито	низький
Витік restricted-досьє	AI Act ст. 10 (дані), GDPR; NIST: Privacy-Enhanced	фільтр доступу до кандидатів у пошуку й рекомендаціях, порти лише 127.0.0.1, локальна LLM	низький
Непрозорість рекомендацій	AI Act ст. 13, 50 (прозорість); NIST: Explainable & Interpretable	пояснення лише зі шляху графа, перевірка сутностей; відповіді агента позначено як згенеровані ШІ	низький
Бульбашка, упередження популярності	NIST: Fair (managed bias), Map 5.1	RRF з графом і ембедингами (coverage 0,39 проти 0,04), слоти нових; план — MMR	середній
Застарілі / замінені регламенти	AI Act ст. 15 (точність); NIST: Manage 4.1 (моніторинг)	фільтр чинності, свіжості; gate якості ЛР14; версії сховища	низький
Надмірна довіра аналітика до системи	AI Act ст. 14 (людський нагляд), ст. 4 (AI-грамотність); NIST: Govern 3.2	HITL для запису знань (propose_fact), рекомендації — підказка, не вердикт; навчання користувачів	середній
Синтетичні дані оцінки ≠ реальна поведінка	NIST: Measure 2.1, 4.2 (валідність оцінки)	чесно позначено; план A/B-тесту й збору журналів зі згодою	високий

Таблиця 3 – Реєстр ризиків і заходів

Govern. Ролі власника знань і рецензента; журнали рішень (ЛР14); правила запису знань лише через HITL (ЛР15).

Measure. Gate якості з 19 перевірок, набори тестів RAG і агента, red teaming, офлайн-оцінка рекомендацій.

Manage. Регресійні прогони після змін корпусу. Регресію RAG на T13 у ЛР14 виявлено саме так.

6. Економіка і вартість

Інфраструктура. Уся система працює на одному ПК студента (CPU, модель 7B у квантуванні Q4). Плата за API відсутня, дані не залишають машину. Головна «вартість» — затримка LLM на CPU.

Операція	Виміряно	Ресурс
Рекомендація (top-5, гібрид RRF + пояснення)	20 мс	CPU, 1 процес; без LLM
Відповідь агента ЛР15 (v3, 12 сценаріїв)	70,2 с у середньому, p95 134,1 с	qwen2.5:7b Q4 на CPU; 6 786 вхідних + 391 вихідних токенів на питання
RAG ЛР11 (k = 3)	p50 23,3 с, p95 41,4 с	те саме
Пошук із reranker ЛР10	≈ 4,6 с на запит	cross-encoder на CPU
Перефразування пояснення (ЛР16)	15,7 с	qwen2.5:7b
Збірка демонстратора з нуля	5,1 хв	образ 944MB, python:3.12-slim без torch

Таблиця 4 – Виміряні витрати ресурсів

Масштабування. Порівняймо з хмарним API за формулою *вартість* = $N \cdot (T_{in} \cdot p_{in} + T_{out} \cdot p_{out})$. На одне питання агента $T_{in} \approx 6\,786$, $T_{out} \approx 391$ токен. Для 1 000 питань на день це ≈ 6,8 млн вхідних і 0,4 млн вихідних токенів. За умовних цін 1 і 5 доларів за мільйон токенів виходить ≈ 8,7 долара на день. Реальні тарифи треба перевіряти на момент рішення. При цьому внутрішні документи довелося б передавати зовнішньому постачальнику, що для restricted-досьє неприйнятно.

Висновок про вартість. Для групи з кількох аналітиків локальний варіант дешевший і безпечніший. Вузьке місце — пропускна здатність: ≈ 70 с на питання на CPU. Підвищити її можна так:

- GPU;
- кешування відповідей;
- маршрутизація простих питань без LLM — рекомендації й пошук уже працюють за десятки мілісекунд.

Трудовитрати. Найдорожчим ресурсом була людська розмітка й перевірка: золоті набори ЛР10–13, ручна перевірка суддів (ЛР11, ЛР14), рішення HITL (ЛР15).

7. Використання генеративного ШІ в проєкті

Два класи генеративного ШІ:

- **LLM-експерт (Claude, Anthropic)** — проєктування, код, тексти документації, аналіз результатів;
- **локальні моделі як компоненти системи** — qwen2.5:7b: Text-to-Cypher/SQL, витяг знань, судді, агент, перефразування пояснень; gemma3:4b: незалежний суддя і червона команда.

Протокол кожної ЛР — `llm_log/` (запит, пропозиція, рішення людини) і `claims/claims.csv` (твердження з рівнем перевірки V1–V4).

Найбільший виграш. LLM-експерт найбільше допоміг зі швидкістю побудови інфраструктури: конвеєри, тестові набори, Docker, документація. Також він знайшов неочевидні причини збоїв — затінення стандартного модуля `profile`, через яке e5 не працювала (ЛР15).

Помилки експерта, виявлені вимірюванням:

- виправлення v2 агента погіршили результат (0,417 → 0,25);
- первинний графовий рекомендатор мав nDCG 0,05 — нормалізація за ступенем «вбивала» сигнал;
- оцінки LLM-суддів були завищені (κ = 0,488);
- LLM гірше за правила витягувала відношення;
- перша (строга) перевірка пояснень відкидала третину правильних перефразувань через відмінкові форми назв — знайдено розбором відмов і виправлено з негативним контролем.

Висновок. Кожну пропозицію LLM перевіряли прогоном, кожне твердження звіту має джерело в `results/`. Усі моделі в продукті локальні, ключів API немає, персональні дані не передавалися.

8. Обмеження

- **Синтетичні журнали взаємодій.** Генератор читає розділи послідовно й обирає документи за темами, тож підіграє ребру NEXT_SECTION і онбордингу за темами. Абсолютні значення метрик не переносяться на реальних користувачів.
- **Малі вибірки:** 12 сценаріїв агента, 31 тест RAG, 50–53 користувачів у test рекомендацій. Інтервали широкі, а різниця між двома гібридами незначуща.
- **Мала LLM на CPU.** Часто обирає не той інструмент, повільна (p95 до 134 с). У 3 з 12 сценаріїв агент дає хибну або неповну відповідь.
- **Покриття графа:** 37 % фрагментів без жодної сутності; газетир чутливий до відмінків.
- **Перевіреність документа** — грубий фільтр. Пороги точності, свіжості й доступності джерел (ЛР14) ще не досягнуто.

9. Наступні кроки

- Пілот із реальними аналітиками: збір журналів зі згодою, онлайн A/B-тест RRF проти популярності, метрика «використано в вердикті».
- Диверсифікація (MMR) і контроль новизни; навчуваний ранжувальник на реальних кліках з тими самими фільтрами.

- Перевіреність на рівні тверджень (вердикти ЛР9) замість документів; автоматичне оновлення джерел для порогів свіжості.
- GPU або менша спеціалізована модель для агента; кеш; маршрутизація питань «граф / OLAP / документи» без LLM.
- CI: gate якості ЛР14, регресія RAG і агента, офлайн-оцінка рекомендацій на кожну зміну корпусу; моніторинг дрейфу.

Джерела

1. Лекція 16 «Рекомендаційні системи, етика та майбутнє систем знань». Курс «Сховища знань та управління знаннями», ЛНУ, 2026.
2. Ricci F., Rokach L., Shapira B. (eds.) Recommender Systems Handbook. 2nd ed. Springer, 2015.
3. Aggarwal C. C. Recommender Systems: The Textbook. Springer, 2016.
4. Регламент (ЄС) 2024/1689 Європейського Парламенту і Ради (Artificial Intelligence Act). OJ L, 12.07.2024.
5. Регламент (ЄС) 2026/1744 (Digital Omnibus on AI) — зміни строків застосування AI Act; огляд: Goodwin, «Not Delayed, Not Deferred: EU AI Act Transparency Obligations Are Now in Force», 08.2026.
6. NIST AI 100-1. Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST, 2023.
7. NIST AI 600-1. AI RMF: Generative Artificial Intelligence Profile. NIST, 2024.
8. Cormack G. V., Clarke C. L. A., Büttcher S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods // SIGIR 2009.
9. Järvelin K., Kekäläinen J. Cumulated Gain-Based Evaluation of IR Techniques // ACM TOIS. 2002. Vol. 20(4).
10. Wang L. et al. Text Embeddings by Weakly-Supervised Contrastive Pre-training (E5). arXiv:2212.03533, 2022.
11. Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // NeurIPS 2020.
12. Yao S. et al. ReAct: Synergizing Reasoning and Acting in Language Models // ICLR 2023.
13. W3C. PROV-O: The PROV Ontology. W3C Recommendation, 2013; W3C. Shapes Constraint Language (SHACL), 2017.

Додаток А. Топ-20 тверджень проєкту

Рівні перевірки: V1 — думка/джерело без перевірки; V2 — перевірено вручну на прикладах; V3 — перевірено на тестовому наборі; V4 — відтворюваний прогін з артефактом у `results/`. Повна таблиця — `claims/claims.csv`.

id	Твердження	Рівень	Статус	Джерело
C01	Гібрид RRF підвищує nDCG@10 з 0,054 ± 0,009 (популярність) до 0,166 ± 0,040 (e5, 5 seed)	V4	verified	results/reco_eval_e5.json
C02	Зважений гібрид (0,179 ± 0,055) і RRF статистично не розрізняються: різниця nDCG@10 0,013, 95 % CI [-0,004; 0,030]	V4	verified	results/paired_e5.json
C03	Оптимальні ваги зваженого гібриду нестабільні між seed: (0.1, 0.6, 0.3); (0.4, 0.5, 0.1); (0.7, 0.3, -0.0); (0.1, 0.5, 0.4); (0.4, 0.4, 0.2)	V4	verified	results/reco_eval_e5.json
C04	Графовий метод сам по собі дає nDCG@10 0,160 ± 0,047 і найвище покриття 0,464 ± 0,026	V4	verified	results/reco_eval_e5.json
C05	Додавання ребер NEXT_SECTION підняло nDCG@10 графового методу з 0,050 до 0,095 (seed 16, LSA)	V3	verified	llm_log/claude_expert.md (№3), results/reco_eval_lsa.json
C06	Гіпотеза: e5 помітно (≥ 0,02 nDCG@10) краща за LSA як ембединги рекомендацій — ембединги e5 0,122 проти LSA 0,117	V4	rejected	results/reco_eval_e5.json, reco_eval_lsa.json
C07	Популярність має найнижчу новизну (6,73 біт) і покриття (0,042)	V4	verified	results/reco_eval_e5.json
C08	Оцінка без витоку з майбутнього: ваги підбираються на validation (до 2026-10-20), фінальна модель бачить лише події до межі test	V2	verified	reco/eval.py
C09	Шаблонні пояснення проходять автоматичну перевірку сутностей у 1,00 випадків (30 рекомендацій)	V4	verified	results/explanations.json
C10	Перефразування qwen2.5:7b проходить перевірку v2 у 0,97 випадків; строга v1 давала 0,67 через хибні відмови на відмінкових формах назв	V4	verified	results/explanations.json, llm_log/explain_llm.jsonl
C11	Перевірка v2 виявляє вставлену сторонню сутність або назву документа в 60 з 60 текстів	V4	verified	results/explanations.json (negative_control)
C12	Новий користувач: онбординг за темами дає nDCG@10 0,157 проти 0,045 у загальної популярності	V4	verified	results/cold_start_e5.json
C13	Гіпотеза: гібрид від обраних тем кращий за популярність у межах тем — 0,157 проти 0,190	V4	rejected	results/cold_start_e5.json
C14	Після 3 взаємодій nDCG@10 зростає до 0,244	V4	verified	results/cold_start_e5.json
C15	Новий документ: RRF показує нові фрагменти рідко (exposure 0,080), 2 слоти підвищують exposure до 0,345	V4	verified	results/cold_start_e5.json
C16	Фільтри доступу застосовуються до ранжування: гість із заявленою роллю admin отримує лише public	V4	verified	demo/demo_run.json (крок 4b), results/filters_demo.json
C17	Фільтр чинності прибирає замінений регламент INT-REG-2025, який інакше стає першою рекомендацією	V4	verified	results/filters_demo.json
C18	Демонстратор запускається з нуля однією командою; збірка 5,1 хв, автоматичний сценарій: 8/8	V4	verified	results/docker_run.json, logs/compose.log, demo/demo_run.md
C19	Hub не є високоризиковою системою за Додатком III AI Act; діють ст. 50 (прозорість) і ст. 4	V1	pending	Регламент (ЄС) 2024/1689, 2026/1744; docs/whitepaper.pdf §5
C20	Синтетичні журнали — головна загроза зовнішній валідності метрик рекомендацій	V1	verified	docs/reco_design.md, обмеження 1